

Временные ряды

Машинное обучение 2, весна 2023

Попов Артём Сергеевич, Малащенко Сергей Анатольевич

Программа AIMasters

Постановка задачи

Дана выборка объектов X , для каждого объект известен его временной ряд (последовательно измеренные через «близкие» промежутки времени данные) y_1, y_2, \dots, y_t .

Необходимо предсказать значения ряда в моменты $t + 1, \dots, t + D$:

- ▶ $\hat{y}_\tau = f(y_{\tau-d}, \dots, y_{\tau-1}, x)$ — предсказание ряда
- ▶ D — горизонт предсказания
- ▶ d — количество моментов времени, используемых для предсказания

Критерий качества — усреднение по рядам регрессионных критериев:

$$L = \frac{1}{ND} \sum_{x \in X} \sum_{\tau=t+1}^{t+D} (\hat{y}_\tau(x) - y_\tau(x))^2 \rightarrow \min$$

Примеры задач

- ▶ Объём продаж в торговой сети
- ▶ Рыночные цены или курсы
- ▶ Объём потребления электроэнергии
- ▶ Объём грузовых и пассажирских перевозок
- ▶ Объём выпускаемой продукции на предприятии
- ▶ Количество посещений сайта
- ▶ Количество заболевших инфекционным заболеванием

Особенности задачи


Основные проблемы при работе с временными рядами:

- ▶ Рядов может быть очень много, а данных по каждому достаточно мало
- ▶ Ряды могут быть очень длинными
- ▶ Разные ряды могут описываться разными моделями
- ▶ Горизонт предсказания может быть достаточно большим
- ▶ Может понадобиться частое перестроение модели с течением времени


Основные особенности временных рядов:

- ▶ тренд (постоянный эффект)
- ▶ сезонность (периодические эффекты)
- ▶ разладка (смена модели ряда)

Пример задачи: подтверждённые случаи COVID-19




Пример задачи: подтверждённые случаи COVID-19




Наблюдения: сезонность, тренд.

Пример задачи: баллы пробок



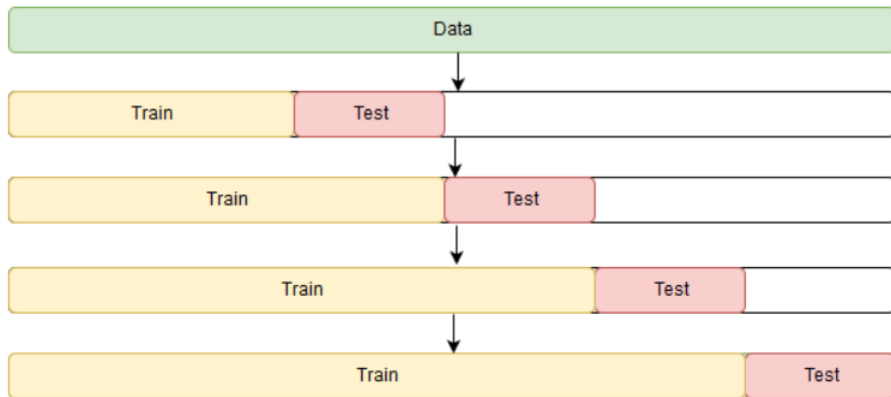
Пример задачи: баллы пробок



Наблюдения: сезонность.

Кросс-валидация при прогнозировании временных рядов

Используем кросс-валидацию по времени:



Модели предсказания временных рядов

- ▶ Статистические модели: ARMA, ARIMA, GARCH, ...
- ▶ Авторегрессионные модели (адаптация ML моделей)
- ▶ Адаптивные модели краткосрочного прогнозирования
- ▶ Нейросетевые модели

Скользящее среднее

Предсказываем следующий элемент ряда взвешенной суммой предыдущих элементов ряда:

$$\hat{y}_{t+1} = \sum_{j=1}^t w_j y_j, \quad \sum_{j=1}^t w_j = 1$$

Простейший вариант — усреднение последних элементов:

$$\hat{y}_{t+1} = \frac{1}{d} \sum_{j=t-d+1}^t y_j, \quad w_j = \mathbb{I}[j \geq t - d].$$

Задача. Пусть $d = t$. Выведите зависимость \hat{y}_{t+1} от \hat{y}_t и y_t .

Скользящее среднее

Предсказываем следующий элемент ряда взвешенной суммой предыдущих элементов ряда:

$$\hat{y}_{t+1} = \sum_{j=1}^t w_j y_j, \quad \sum_{j=1}^t w_j = 1$$

Простейший вариант — усреднение последних элементов:

$$\hat{y}_{t+1} = \frac{1}{d} \sum_{j=t-d+1}^t y_j, \quad w_j = \mathbb{I}[j \geq t - d].$$

Задача. Пусть $d = t$. Выведите зависимость \hat{y}_{t+1} от \hat{y}_t и y_t .

$$\hat{y}_{t+1} = \frac{1}{t}((t-1)\hat{y}_t + y_t) = \hat{y}_t + \frac{1}{t}(y_t - \hat{y}_t)$$

Экспоненциальное скользящее среднее (ЭСС)

Зададим веса по формуле Надарая-Ватсона:

$$\hat{y}_{t+1} = \sum_{j=1}^t w_j y_j, \quad w_j = \frac{\beta^{t-j}}{\sum_{k=1}^t \beta^{t-k}}, \quad \beta \in (0, 1)$$

Задача. Выведите зависимость \hat{y}_{t+1} от \hat{y}_t и y_t .

Экспоненциальное скользящее среднее (ЭСС)

Зададим веса по формуле Надарая-Ватсона:

$$\hat{y}_{t+1} = \sum_{j=1}^t w_j y_j, \quad w_j = \frac{\beta^{t-j}}{\sum_{k=1}^t \beta^{t-k}}, \quad \beta \in (0, 1)$$

Задача. Выведите зависимость \hat{y}_{t+1} от \hat{y}_t и y_t .

Если приблизить $\sum_{k=1}^t \beta^{t-k} \approx \sum_{k=1}^{\infty} \beta^{t-k} = \frac{1}{1-\beta}$, то можно получить:

$$\hat{y}_{t+1} = \beta \hat{y}_t + (1 - \beta) y_t = \alpha y_t + (1 - \alpha) \hat{y}_t, \quad \alpha = 1 - \beta$$

Чем больше α , тем больше вес последних точек. Если «оптимальное» по отложенной выборке $\alpha \in (0, 0.3)$, то ряд скорее всего стационарен.


Использование других средних

Среднее по Колмогорову:

$$\hat{y}_{t+1} = \phi^{-1} \left(\frac{\sum_{i=1}^t w_i \phi(y_i)}{\sum_{i=1}^t w_i} \right)$$

- ▶ Арифметическое, $\phi(y) = y$
- ▶ Геометрическое, $\phi(y) = \log(y)$
- ▶ Гармоническое, $\phi(y) = y^{-1}$
- ▶ Квадратичное, $\phi(y) = y^2$

Стандартные эффекты на модельных данных



Ряд 1 — сезонность без тренда

Ряд 2 — линейный тренд, аддитивная сезонность

Ряд 3 — линейный тренд, мультипликативная сезонность

Ряд 4 — экспоненциальный тренд, мультипликативная сезонность

Модель с линейным трендом

Предсказание задаётся как сумма смещения и тренда:

$$\hat{y}_{t+1} = a_{t+1} + b_{t+1}$$

Смещение вычисляется с помощью ЭСС как и раньше:

$$a_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t = \alpha y_t + (1 - \alpha)(a_t + b_t)$$

Тренд вычисляется с помощью ЭСС по разностям соседних смещений:

$$b_{t+1} = \beta(a_{t+1} - a_t) + (1 - \beta)b_t$$

Модель с линейным трендом на d шагов вперёд

Предполагаем, что тенденция, задаваемая последними элементами ряда, продолжится:

$$\hat{y}_{t+d} = a_{t+1} + db_{t+1}$$

$$a_{t+1} = \alpha y_t + (1 - \alpha)(a_t + b_t)$$

$$b_{t+1} = \beta(a_{t+1} - a_t) + (1 - \beta)b_t$$

Модель с линейным трендом и сезонностью

Пусть у нас есть аддитивная сезонность с периодом s :

$$\hat{y}_{t+d} = a_{t+1} + db_{t+1} + c_{t+d \bmod s-s}$$

Смещение очищается от сезонности:

$$a_{t+1} = \alpha(y_t - c_{t-s}) + (1 - \alpha)(a_t + b_t)$$

Тренд не меняется:

$$b_{t+1} = \beta(a_{t+1} - a_t) + (1 - \beta)b_t$$

Сезонность вычисляется с помощью ЭСС по элементам ряда без смещения:

$$c_{t+1} = \gamma(y_t - a_t) + (1 - \gamma)c_t$$

Краткое резюме

- ▶ Такие модели можно использовать в качестве бейзлайна
- ▶ Над такими моделями можно строить ансамбли
- ▶ Результаты моделей можно использовать в качестве признаков
- ▶ Такие модели можно использовать, когда рядов очень много, а данные не очень хорошие

Авторегрессионные модели

Хотим свести задачу предсказания новых элементов ряда к стандартной задаче регрессии.

Поделим временной ряд на несколько отрезков, каждый отрезок будет соответствовать одной строке в матрице признаков:

$$X_{train} = \begin{pmatrix} y_1 & y_2 & \dots & y_d \\ y_2 & y_3 & \dots & y_{d+1} \\ \vdots & \vdots & \vdots & \vdots \\ y_{t-d} & y_{t-d+1} & \dots & y_{t-1} \end{pmatrix}, \quad y_{train} = \begin{pmatrix} y_{d+1} \\ y_{d+2} \\ \vdots \\ y_t \end{pmatrix}$$

Основной плюс подхода: легко добавить в данные самые разные признаки.

Составление матрицы признаков

- ▶ Количество дней d — гиперпараметр, который нужно подбирать
- ▶ Необязательно строить вектор ответов для всех моментов времени
- ▶ Чтобы в моменте t учесть сезонность с периодом s , следует добавить наблюдения произошедшие ks моментов времени от t назад:

$$x = (y_{t-d}, \dots, y_{t-1}, y_{t-s}, y_{t-2s}, \dots, y_{t-ks}), \quad y = y_t$$

- ▶ Если в данных есть пропуски, можно ввести признак «известно ли значение»
- ▶ Для разных рядов может быть разным первый отрезок времени, который нужно добавить в выборку
- ▶ Некоторые нетипичные отрезки времени не стоит добавлять в выборку

Предсказания на d значений вперёд

Предсказания на d значений вперёд

Рекурсивный подход:

$$\hat{y}_{t+1} = f(y_{t-d}, \dots, y_{t-1}, y_t)$$

$$\hat{y}_{t+2} = f(y_{t-d+1}, \dots, y_t, \hat{y}_{t+1})$$

$$\hat{y}_{t+3} = f(y_{t-d+2}, \dots, \hat{y}_{t+1}, \hat{y}_{t+2})$$

Специальный признак (отвечающий за момент предсказания):

$$\hat{y}_{t+1} = f(y_{t-d}, \dots, y_{t-1}, y_t, 1)$$

$$\hat{y}_{t+2} = f(y_{t-d}, \dots, y_{t-1}, y_t, 2)$$

$$\hat{y}_{t+3} = f(y_{t-d}, \dots, y_{t-1}, y_t, 3)$$

Предсказания на d значений вперёд

Многомодельный подход:

$$\hat{y}_{t+1} = f_1(y_{t-d}, \dots, y_{t-1}, y_t)$$

$$\hat{y}_{t+2} = f_2(y_{t-d}, \dots, y_{t-1}, y_t)$$

$$\hat{y}_{t+3} = f_3(y_{t-d}, \dots, y_{t-1}, y_t)$$

Многомодельный рекурсивный подход:

$$\hat{y}_{t+1} = f_1(y_{t-d}, \dots, y_{t-1}, y_t)$$

$$\hat{y}_{t+2} = f_2(y_{t-d+1}, \dots, y_t, \hat{y}_{t+1})$$

$$\hat{y}_{t+3} = f_3(y_{t-d+2}, \dots, \hat{y}_{t+1}, \hat{y}_{t+2})$$

Сравнение подходов

	Recursion	Feature	Several models	Recursive models
объём данных (обучение)	N	ND	N	N
сложно перестраивать матрицу на тесте	+	-	-	+
количество моделей	1	1	D	D
согласованность предсказаний	+	-	-	+
много памяти на хранение модели	-	-	+	+

Полезные ссылки

- ▶ Открытый курс машинного обучения. Анализ временных рядов с помощью Python. (ссылка)
- ▶ К.В. Воронцов. Машинное обучение. Прогнозирование временных рядов. (ссылка)